FedAvg vs FedProx 비교 실험 보고서

Non-IID (Dirichlet α=0.3) CIFAR-10 · Flower 1.36 · AWS SuperLink + Mac / Windows Desktop SuperNode · 2026-11-09 실행

> **요약.** 클라이언트 2개, 10라운드 조건에서 **FedAvg가 정확도에서 앞섰다**. 최종 정확도는 FedAvg 52.38%, FedProx(μ=0.1) 41.72%로 10.66%p 차이가 났다. 최고 정확도도 53.21%와 43.70%로 FedAvg가 높았다. 반면 FedAvg는 4라운드 이후 서버 손실이 최저점보다 25.3% 다시 올랐다. FedProx는 같은 지표의 상승이 3.5%에 그쳤다. 즉 FedProx는 더 느리게 학습했지만 손실은 더 안정적이었다. 단, 시드 1회 실험이고 μ도 한 가지 값만 시험했기 때문에 일반적인 결론으로 보기는 어렵다.

1. 실험 목적

클라이언트마다 라벨 분포가 크게 다른 Non-IID 환경에서, 근접항(proximal term)을 추가한 FedProx가 FedAvg보다 수렴과 안정성이 나은지 확인한다.

2. 실험 환경 및 설정

항목	값
프레임워크	Flower 1.36 (Deployment Engine, `flwr run . aws`)
구성	SuperLink: AWS EC2 · SuperNode 2개: Windows Desktop(partition 0), Mac(partition 1) · Tailscale 연결
데이터	CIFAR-10 학습셋 50,000장을 Dirichlet(α=0.3, seed=42)로 2분할하고, 노드마다 80% 학습 / 20% 로컬 평가로 나눔
모델	간단한 CNN (Conv 2층 + FC 3층, PyTorch 60 Minute Blitz 기반)
로컬 학습	SGD (lr=0.01, momentum=0.9), batch 32, local epoch 3
연합 학습	10라운드, 매 라운드 2개 노드 전원 참여 (fraction-evaluate=1.0)
비교 대상	FedAvg (μ=0) vs FedProx (μ=0.1). 손실에 $(\mu/2)\cdot \lVert w - w_{global} \rVert^2$를 더함
평가	서버: CIFAR-10 test 10,000장 전역 평가 · 클라이언트: 로컬 20% 평가셋의 가중 평균
소요 시간	FedAvg 7분 03초 · FedProx 6분 57초

데이터 분포 (Non-IID 정도)

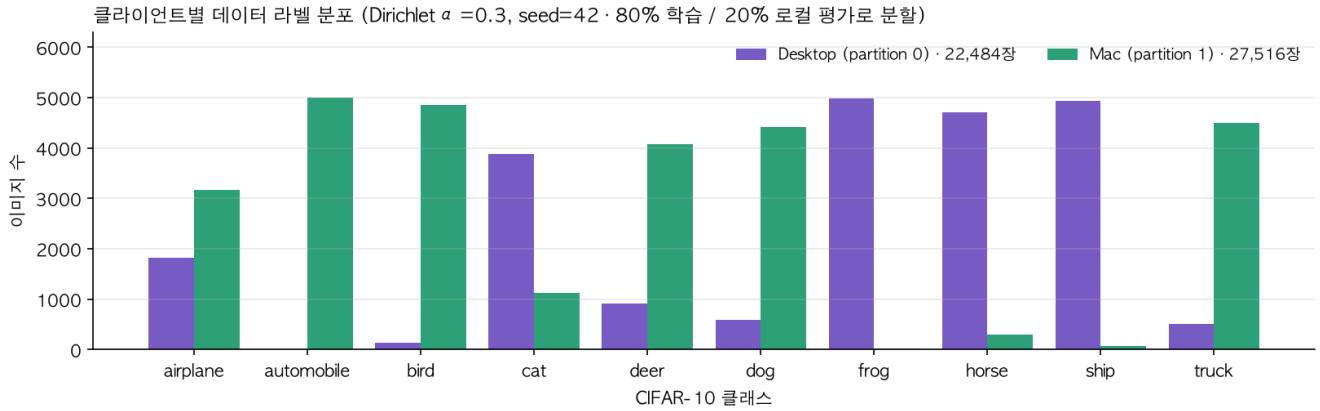


그림 1. 두 노드의 라벨 분포가 거의 겹치지 않는다. Desktop은 frog·horse·ship·cat 위주이고 automobile은 4장뿐이다. Mac은 automobile·bird·truck·dog 위주이고 frog 22장, ship 69장, horse 295장으로 이 세 클래스가 거의 없다. 노드 하나만으로는 10개 클래스를 고르게 학습할 수 없는 강한 Non-IID 조건이다.

3. 결과

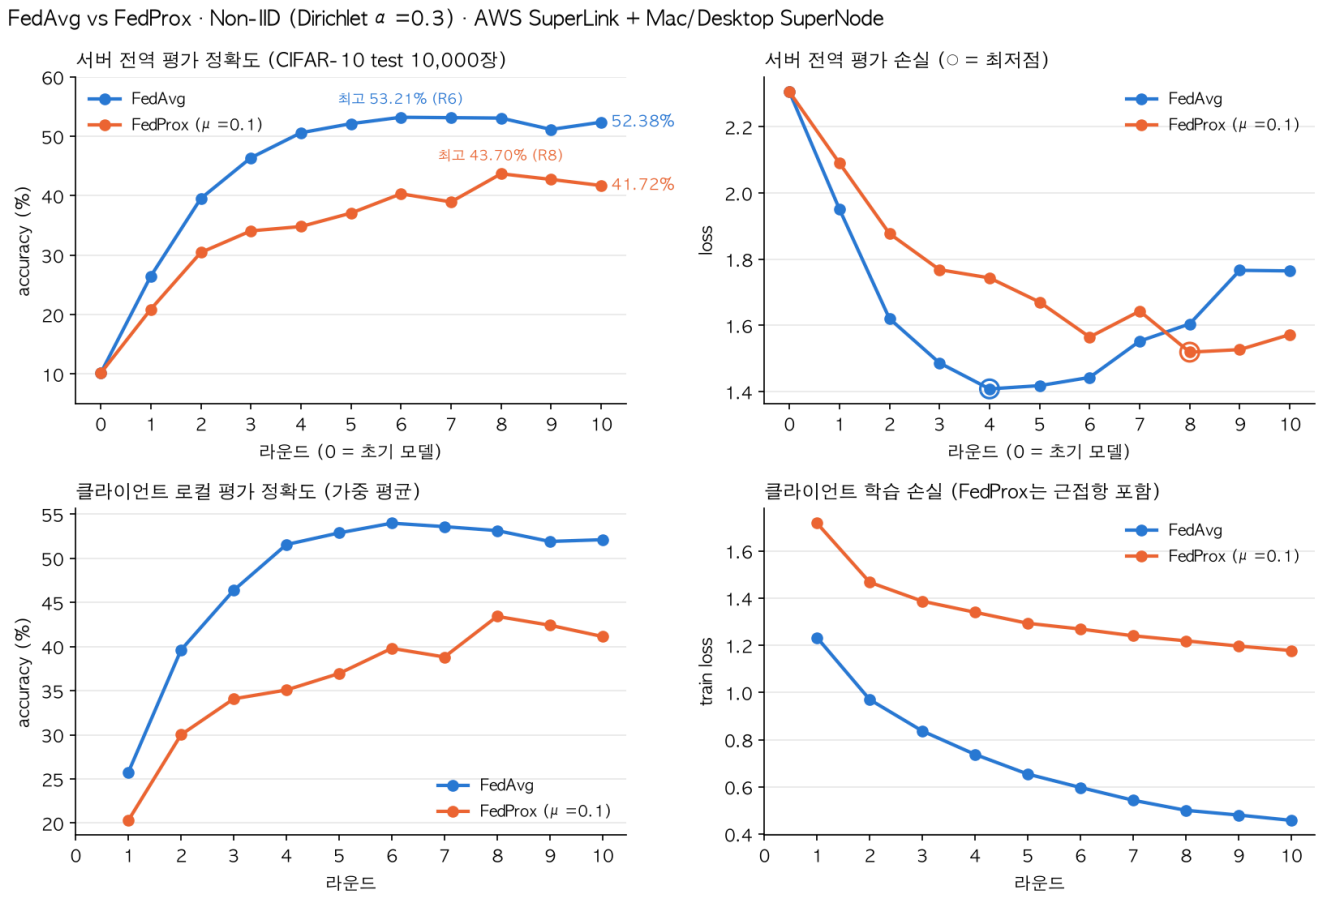


그림 2. 라운드별 서버 전역 정확도와 손실, 클라이언트 로컬 평가 정확도, 클라이언트 학습 손실

지표 (서버 전역 평가)	FedAvg	FedProx (μ=0.1)	차이
최종 정확도 (R10)	**52.38%**	41.72%	+10.66%p
최고 정확도	**53.21% (R6)**	43.70% (R8)	+9.51%p
R6-R10 평균 정확도	**52.59%**	41.49%	+11.10%p
R6-R10 정확도 표준편차 (흔들림)	**0.78%p**	1.69%p	
40% 도달 라운드 / 50% 도달 라운드	**R3 / R4**	R6 / 도달 못함	
최저 손실	**1.408 (R4)**	1.519 (R8)	
최종 손실 (R10)	1.765	**1.572**	
최저점 대비 최종 손실 상승률	+25.3%	**+3.5%**	
클라이언트 로컬 평가 최종 정확도	**52.10%**	41.14%	+10.96%p

4. 분석

- **수렴 속도는 FedAvg가 빨랐다.** FedAvg는 4라운드에 50%를 넘었다. FedProx는 6라운드에야 40%를 넘었고 10라운드 안에 50%에 도달하지 못했다. 근접항이 로컬 모델을 전역 모델 가까이 묶어 두기 때문에, 라운드당 학습할 수 있는 양이 줄어든 것으로 보인다.
- **FedAvg는 4라운드 이후 과적합이나 클라이언트 드리프트로 보이는 신호를 보였다.** 정확도는 52-53%에서 정체됐다. 그런데 서버 손실은 1.408(R4)에서 1.765(R10)로 계속 올랐다. 이는 맞히는 비율은 같아도, 틀린 예측에 대한 확신이 커졌다는 뜻이다. 각 노드가 자기 데이터에 치우친 방향으로 3 epoch씩 학습해서 생긴 현상으로 해석된다.
- **FedProx는 손실이 더 안정적이었다.** 최저점 이후 손실 상승이 3.5%에 그쳤고, 정확도는 8라운드까지 꾸준히 올랐다. 이는 FedProx가 의도한 효과인 로컬 모델 이탈 억제와 일치한다. 다만 라운드 간 정확도 흔들림은 FedProx가 더 컸다 (R7, R9-R10 하락).
- **학습 손실 그래프는 직접 비교할 수 없다.** FedProx의 train loss에는 근접항이 더해져 있어서 원래 높게 나온다. 그래서 그림 2 오른쪽 아래 그래프의 차이를 FedProx가 덜 학습됐다는 근거로 쓰면 안 된다.
- **이번 조건은 FedProx에 유리한 환경이 아니었다.** FedProx는 원래 시스템 이질성에 대응하려고 만든 방법이다. 예를 들어 노드마다 로컬 학습량이 다르거나, 일부 노드만 참여하거나, 지연 노드가 있는 상황이다. 이번 실험은 노드 2개가 매 라운드 똑같이 3 epoch를 학습했다. 또 10라운드는 짧아서 FedAvg의 드리프트가 정확도를 크게 떨어뜨리기 전에 실험이 끝났다.

5. 한계

- 시드 1회, 실행 1회 결과라서 분산을 알 수 없다. 10%p 차이는 크지만, 라운드별 1-2%p 차이는 우연일 수 있다.
- μ를 0.1 하나만 시험했다. 이 CNN과 momentum 0.9 조합에서는 0.1이 너무 셌을 수 있다. 원래 계획했던 μ=0.01과 μ=1.0은 AWS 서버를 끄면서 중단됐다.
- 클라이언트가 2개뿐이라 일반적인 연합학습 환경(수십-수백 노드, 부분 참여)과는 거리가 있다.
- 모델이 작고 라운드 수가 적어서 정확도 절대값이 낮다 (최고 53%).

6. 결론 및 다음 실험

이번 설정(노드 2개, 전원 참여, 10라운드, μ=0.1)에서는 정확도 기준으로 FedAvg가 FedProx보다 약 10%p 높았다. 대신 FedAvg는 4라운드 이후 손실이 25% 다시 올랐고, FedProx는 손실이 거의 오르지 않았다. 따라서 FedProx의 장점을 확인

하려면 μ를 더 작게 잡고, 라운드를 늘려서 다시 비교해야 한다.

- 중단된 μ=0.01, μ=1.0 실행을 마친다. μ=0.01은 FedAvg에 가까운 속도를 내면서 손실 상승을 줄일 수 있는지 확인하는 용도다.
- 라운드를 30회 이상으로 늘려서, FedAvg의 드리프트가 정확도 하락으로 이어지는지 본다.
- 시드 3개 이상으로 반복해서 평균과 표준편차를 보고한다.
- 노드별 local epoch를 다르게 주는(예: 1 vs 5) 시스템 이질성 조건을 추가한다.

원자료: `~/FL/NonIID/results/noniid_fedavg.json`, `noniid_fedprox_mu0.1.json` · 그래프 코드: `~/FL/NonIID/plot_compare.py` · 라벨 분포: `fedcompare.task.label_hist` 로 재계산